

设 w_i 为输入单词, d_{model} 为模型维度, $\mathbf{e}_i$ 为嵌入向量:

$$\mathbf{e}_i = \text{Embedding}(w_i) \in \mathbb{R}^{d_{\text{model}}}$$

位置编码 $\mathbf{p}_i$ 定义为:

$$\begin{aligned}\text{PE}_{(pos, 2k)} &= \sin(pos/10000^{2k/d_{\text{model}}}) \\ \text{PE}_{(pos, 2k+1)} &= \cos(pos/10000^{2k/d_{\text{model}}})\end{aligned}$$

最终的输入表示 $\mathbf{x}_i$ 为:

$$\mathbf{x}_i = \mathbf{e}_i + \mathbf{p}_i$$

给定 $\mathbf{x}_i$, 查询、键和值向量计算如下:

$$\begin{aligned}\mathbf{q}_i &= \mathbf{x}_i W^Q \\ \mathbf{k}_i &= \mathbf{x}_i W^K \\ \mathbf{v}_i &= \mathbf{x}_i W^V\end{aligned}$$

注意力机制定义为:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

对于操作 $a + b$, 结果 c 的预测为:

$$\arg \max_c P(c|a, \text{操作}, b; \theta)$$

混合系统结合了神经网络 N 和符号系统 S :

$$H(\text{输入}) = N(\text{输入}, S_{\text{查询}}(\text{输入}))$$

一个前馈函数的示例:

$$f(x) = W_2 \cdot \text{ReLU}(W_1 \cdot x + b_1) + b_2$$

在某些上下文中, 输出向量 $\mathbf{y}_i$ 可以表示为:

$$\mathbf{y}_i = f(\mathbf{x}_i, \{\mathbf{x}_j\}_{j=1}^n) \quad (\text{概念性公式, 基于 D2DL Eq. 10.6.1})$$

普通交叉熵损失定义为:

$$\mathcal{L}_{\text{CE}}(\theta) = - \sum_{k=1}^V t_k \log p_k$$

其中:

- θ 是模型的参数。
- V 是词汇表的大小。
- t_k 是目标分布（通常是 one-hot 编码）。
- $p_k = P(w = k|\text{context}; \theta)$ 是模型预测词汇表中第 k 个词元的概率。

带有标签平滑的交叉熵损失定义为：

$$\mathcal{L}_{\text{smooth}}(\theta) = - \sum_{k=1}^V t'_k \log p_k = - \left((1 - \epsilon) \log p_y + \sum_{k \neq y} \frac{\epsilon}{V-1} \log p_k \right)$$

掩码语言模型损失定义为：

$$\mathcal{L}_{\text{MLM}}(\theta) = - \sum_{i \in M} \log P(w_i | \text{context}_{\text{masked}}; \theta)$$

强化学习目标 (PPO) 的核心公式为：

$$J_{\text{PPO}}(\theta) = \mathbb{E}_{x \sim D, y \sim \pi_{\theta}(y|x)} [R(x, y) - \beta \cdot \text{KL}(\pi_{\theta}(y|x) || \pi_{\text{ref}}(y|x))]$$

直接偏好优化损失定义为：

$$\mathcal{L}_{\text{DPO}}(\theta, \pi_{\text{ref}}) = - \mathbb{E}_{(x, y_w, y_l) \sim D_{\text{pref}}} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_{\theta}(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right) \right]$$

模型的运算是高维向量空间中的几何变换。例如，对于加法“3 + 5 = 8”，模型学习到的复杂函数 f_{θ} 目标是使得处理输入序列“3 + 5 =”后的输出向量在概率上最接近目标“8”的向量表示 $\mathbf{x}_8$ ：

$$f_{\theta}(\text{Context}(\mathbf{x}_3, \mathbf{x}_+, \mathbf{x}_5, \mathbf{x}_=)) \rightarrow \text{Probability Distribution over Vocabulary}$$

且该分布在 $\mathbf{x}_8$ 处概率最高。

Softmax 函数定义为：

$$\text{softmax}(z_i) = \frac{\exp(z_i)}{\sum_{j=1}^n \exp(z_j)}$$

其中：

- z_i 是输入向量 z 中的第 i 个元素。
- n 是输入向量的维度。
- $\exp$ 表示指数函数。